
LLMs on Similarity between Stories and Games

13 messages

Salvatore Nunnari <salvatore.nunnari@gmail.com>

Wed, May 20, 2026 at 3:51 PM

To: Andrea Amelio <andrea.amelio@unibocconi.it>, Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

Ciao Nicola e Andrea,

vi mando i risultati dell'esercizio LLM che Nicola aveva proposto qualche settimana fa: chiedere a un LLM quanto Aid e Bonus assomiglino strutturalmente a DG, UG e TG, con l'ipotesi che TG fosse il più distante per via dei gains from cooperation.

Ho fatto girare l'esercizio con tre modelli (Claude Opus 4.7, ChatGPT 5.5 Thinking, Gemini 3.1 Pro), in tre conversazioni separate per modello, ognuna con una permutazione diversa di etichette neutre (A/B/C/D per i giochi, Story 1/Story 2 per le storie), così da escludere effetti di posizione e di prior dei modelli sulla letteratura DG/UG/TG. Tre prompt per conversazione: (i) similarity ratings 0–100 per ognuna delle 8 coppie storia × gioco, (ii) decomposizione strutturale lungo cinque dimensioni, (iii) retrieval inverso — dato il gioco, quale storia viene in mente. In totale 9 conversazioni e 72 ratings di similarità.

Risultati:

1. L'intuizione di Nicola è confermata in modo netto. L'ordine medio di similarità è DG-KW > DG-LT > UG > TG, con medie 94.6 / 51.2 / 29.9 / 14.4 sulla scala 0–100. L'ordine vale in tutti e tre i modelli e in tutte e tre le permutazioni; i range tra triplet sono piccoli (1.5–10.3 punti), quindi effetti di posizione o di etichetta non contano. Tutti i modelli identificano la struttura del budget (espandibile vs fisso) come la dimensione che isola TG dagli altri tre giochi, esattamente la lettura "gains from cooperation".
2. Bonus e Aid sono praticamente indistinguibili a livello di similarità assoluta, meno di un punto di differenza in media per ogni gioco. Quindi l'eventuale asimmetria comportamentale che troviamo nell'esperimento non passa attraverso una diversa struttura percepita rispetto ai giochi.
3. La direzione di retrieval (gioco → storia) racconta una storia diversa e, secondo me, interessante. Nel terzo prompt ho chiesto al modello, per ogni gioco, di distribuire 100 punti tra Bonus e Aid in base a quale delle due storie il gioco gli richiamasse di più come esperienza simile (50/50 = parità; 70/30 = Bonus molto più richiamata di Aid). La media dei punti assegnati a Bonus sale monotonicamente lungo l'asse dei giochi: 41% per DG-KW, 54% per DG-LT, 60% per UG, 72% per TG. Quindi per il dittatore Aid viene richiamata leggermente di più di Bonus, mentre man mano che il gioco si arricchisce strategicamente Bonus prende il sopravvento; questo avviene perché Bonus contiene cue di produzione congiunta e relazione continuativa (features di superficie/contesto) che mancano in Aid, anche se strutturalmente (allocatore unico, recipient passivo, budget fisso) le due storie sono identiche.

Ho messo tutto nel file .zip che allego: i prompt che ho usato, i transcript delle 9 conversazioni, e un Excel con i ratings e le tabelle riassuntive.

A presto,
Salvo

--

Salvatore Nunnari
Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>
<https://zoom.us/my/snunnari>

 LLM_Similarity.zip
78K

Grazie Salvo, super interessante! Super cool che TG sia il meno simile a stories, sicuramente è un'ottima cartuccia da avere.

Un paio di chiarimenti:

- (1) e (2) vogliono dire che il ranking di similarità di Aid e Bonus rispetto ai giochi è lo stesso, giusto?
- Trovo (2) abbastanza sorprendente; mi sarei aspettato che Bonus dominasse stocasticamente Aid across games. Su questo, è possibile che il prompt spinga in questa direzione dicendogli "Focus on the structural and strategic features of the situation, not on surface thematic content."? Sicuramente è un'ottima proof of concept che abbiamo costruito le stories in maniera sensata comunque, dato che l'intento era esattamente quello di variare il contesto senza variare aspetti strutturali.
- Anche l'esercizio inverso super cool! Connesso al punto di prima, mi chiedo se la differenza di risultati fra gli esercizi possa dipendere dal fatto che qui, a differenza del caso opposto, gli permetti di usare elementi contestuali. Magari questa "asimmetria" è dovuta alle differenze nel prompt? Forse sarebbe interessante chiedergli in maniera libera cosa gli viene in mente da ciascun gioco e poi fare la similarità della sua risposta libera con Aid e Bonus?

Che ne pensi? Grazie!

Andrea

From: Salvatore Nunnari <salvatore.nunnari@gmail.com>

Sent: Wednesday, May 20, 2026 3:51 PM

To: Andrea Amelio <andrea.amelio@unibocconi.it>; Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

Subject: LLMs on Similarity between Stories and Games

[Quoted text hidden]



Please note that the above message is addressed only to individuals filing Italian income tax returns.

5x1000 is a percentage of Italian personal income tax that taxpayers can allocate to Universities, scientific research and non profit organizations.

Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

Wed, May 20, 2026 at 4:29 PM

To: Salvatore Nunnari <salvatore.nunnari@gmail.com>, Andrea Amelio <andrea.amelio@unibocconi.it>

Grazie Salvo,

super interessante! Dovremmo provare una regressione dove guardiamo al treatment effect as a function of total similarity in 1 e relative similarity in 3, all relative to control.

From: Salvatore Nunnari <salvatore.nunnari@gmail.com>

Sent: Wednesday, May 20, 2026 15:51

To: Andrea Amelio <andrea.amelio@unibocconi.it>; Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

Subject: LLMs on Similarity between Stories and Games

[Quoted text hidden]

[Quoted text hidden]

Salvatore Nunnari <salvatore.nunnari@gmail.com>
To: Nicola Gennaioli <nicola.gennaioli@unibocconi.it>
Cc: Andrea Amelio <andrea.amelio@unibocconi.it>

Wed, May 20, 2026 at 4:49 PM

Ciao a entrambi, grazie dei commenti.

Alcune risposte rapide, e per il resto propongo di parlarne di persona.

@Andrea

(1) Sì, e anche più forte: per ogni gioco i punteggi di Aid e Bonus sono praticamente identici (gap medio <1 punto su 100), non solo l'ordering. Sono indistinguibili gioco per gioco.

(2) Sono d'accordo con il tuo commento sulla componente del prompt "focus on structural/strategic features, not surface thematic content". È plausibile che comprima artificialmente la differenza, dato che di fatto chiedo al modello di ignorare proprio le dimensioni su cui le due storie variano. Vale la pena tenerlo a mente (e potremmo rifare l'esercizio senza quella frase per vedere cosa cambia) anche se sono d'accordo con la tua altra lettura: il risultato è anche una prova che le storie sono costruite come volevamo, cioè variano contesto senza variare struttura.

(3) Sì, idea interessante. Prima di sviluppare un secondo esercizio però vorrei capire insieme a voi che ruolo avrebbero queste evidenze nel paper. Parliamone di persona al prossimo incontro.

@Nicola

Ti chiedo un chiarimento sulla regressione che hai in mente. Le nostre unità di osservazione sono individui, mentre le similarities da LLM sono a livello (game × story). Volevi quindi (i) portare le similarities come moderatori, cioè interagite con le dummy di trattamento a livello individuale oppure (ii) un'analisi aggregata a livello di cella (con $N = 4 \times 2$)? Entrambe sono fattibili ma rispondono a domande diverse.

Più in generale: che ne dite se ci incontriamo ad un certo punto la settimana prossima per fare il punto e capire cosa ci manca o cosa abbia maggiore priorità per scrivere il paper?

A presto!
Salvo

--
Salvatore Nunnari
Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>
<https://zoom.us/my/snunnari>

[Quoted text hidden]

Salvatore Nunnari <salvatore.nunnari@gmail.com>
To: Nicola Gennaioli <nicola.gennaioli@unibocconi.it>
Cc: Andrea Amelio <andrea.amelio@unibocconi.it>

Wed, May 20, 2026 at 4:57 PM

PS: Venerdì ospito Guillaume Frechette ma, se preferite che ci incontriamo questa settimana, sono disponibile anche domani 9:00-12:00 e 14:30-16:30.

--
Salvatore Nunnari

Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>
<https://zoom.us/my/snunnari>

[Quoted text hidden]

Nicola Gennaioli <nicola.gennaioli@unibocconi.it>
To: Salvatore Nunnari <salvatore.nunnari@gmail.com>

Wed, May 20, 2026 at 5:55 PM

Domani alle 3 pm perfetto per me.

From: Salvatore Nunnari <salvatore.nunnari@gmail.com>
Sent: Wednesday, May 20, 2026 16:57
To: Nicola Gennaioli <nicola.gennaioli@unibocconi.it>
Cc: Andrea Amelio <andrea.amelio@unibocconi.it>
Subject: Re: LLMs on Similarity between Stories and Games

[Quoted text hidden]

Salvatore Nunnari <salvatore.nunnari@gmail.com>
To: Nicola Gennaioli <nicola.gennaioli@unibocconi.it>, Andrea Amelio <andrea.amelio@unibocconi.it>

Wed, May 20, 2026 at 5:57 PM

Ottimo! @Andrea: tu puoi domani alle 3pm?

Salvatore Nunnari
Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>
<https://zoom.us/my/snunnari>

[Quoted text hidden]

Andrea Amelio <andrea.amelio@unibocconi.it>
To: Salvatore Nunnari <salvatore.nunnari@gmail.com>, Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

Wed, May 20, 2026 at 6:07 PM

Sì, va bene per me, a domani!

From: Salvatore Nunnari <salvatore.nunnari@gmail.com>
Sent: Wednesday, May 20, 2026 5:57 PM
To: Nicola Gennaioli <nicola.gennaioli@unibocconi.it>; Andrea Amelio <andrea.amelio@unibocconi.it>

[Quoted text hidden]

[Quoted text hidden]

Salvatore Nunnari <salvatore.nunnari@gmail.com>
To: Andrea Amelio <andrea.amelio@unibocconi.it>

Thu, Jun 4, 2026 at 7:51 PM

Secondo te è questo (o una sua versione) quello che ha in mente Nicola nella seconda parte della sua ultima email?

Salvatore Nunnari
Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>

<https://zoom.us/my/snunnari>

----- Messaggio inoltrato -----

Da: **Andrea Amelio** <andrea.amelio@unibocconi.it>

Data: mer 20 mag 2026 alle 18:07

Oggetto: Re: LLMs on Similarity between Stories and Games

A: Salvatore Nunnari <salvatore.nunnari@gmail.com>, Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

[Quoted text hidden]

Andrea Amelio <andrea.amelio@unibocconi.it>
To: Salvatore Nunnari <salvatore.nunnari@gmail.com>

Fri, Jun 5, 2026 at 9:09 AM

Non sono sicuro: è possibile, anche se non è chiaro cosa usare come riferimento per "cooperation problem" o "moral problem" to make the statement, e.g., "market DG is more similar to the cooperation problem than to controlDG" .

Comunque una versione di questo approccio è una strada, ma non sono sicuro che lui ne avesse in mente una specifica quando ha scritto.

From: Salvatore Nunnari <salvatore.nunnari@gmail.com>
Sent: Thursday, June 4, 2026 7:51 PM
To: Andrea Amelio <andrea.amelio@unibocconi.it>
Subject: Fwd: LLMs on Similarity between Stories and Games

[Quoted text hidden]

Salvatore Nunnari <salvatore.nunnari@gmail.com>
To: Andrea Amelio <andrea.amelio@unibocconi.it>

Fri, Jun 5, 2026 at 12:08 PM

Ho parlato con Nicola.

Questo è quello che aveva in mente:

1. We give an LLM as input a description of a "Moral Problem" and a description of a "Cooperation Problem" or a definition of Morality and a definition of Cooperation (there could also be more than two categories); this could be the prompts we use to classify the Reasons/HP answers or something else (e.g., canonical game-theoretical environments as a coordination/cooperation game vs a zero-sum game vs a social dilemma game).
2. We ask the LLM to create "real-world scenarios" or "vignettes" that exemplify these 2 or 3 general descriptions.
3. We ask the LLM to score the similarity between these "vignettes" and our games.
4. We could do something similar with the Aid and Bonus stories (that is, score their similarity with these vignettes).
5. Once we find something that "works" with LLMs, we can do this with human raters.

Thoughts?

S

--

Salvatore Nunnari
Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>
<https://zoom.us/my/snunnari>

[Quoted text hidden]

Andrea Amelio <andrea.amelio@unibocconi.it>
To: Salvatore Nunnari <salvatore.nunnari@gmail.com>

Sun, Jun 7, 2026 at 2:17 PM

Interessante! La parte su cui avevo dubbi era proprio gli steps 1 e 2.

Questa comunque sarebbe ulteriore evidence che corrobora la nostra tesi, giusto? Quindi credo che sarebbe più prioritario definire la backbone del paper prima di fare queste analisi aggiuntive. Concordi?

From: Salvatore Nunnari <salvatore.nunnari@gmail.com>
Sent: Friday, June 5, 2026 12:08 PM
To: Andrea Amelio <andrea.amelio@unibocconi.it>
Subject: Re: LLMs on Similarity between Stories and Games

[Quoted text hidden]

Salvatore Nunnari <salvatore.nunnari@gmail.com> Fri, Jul 10, 2026 at 3:09 PM
To: Andrea Amelio <andrea.amelio@unibocconi.it>, Nicola Gennaioli <nicola.gennaioli@unibocconi.it>

Questo il thread su similarity.

Inoltre, queste le mie note di una conversazione che ho avuto con Nicola su un approccio alternativo:

1. We give an LLM as input a description of a "Moral Problem" and a description of a "Cooperation Problem" or a definition of Morality and a definition of Cooperation (there could also be more than two categories); this could be the prompts we use to classify the Reasons/HP answers or something else (e.g., canonical game-theoretical environments as a coordination/cooperation game vs a zero-sum game vs a social dilemma game).
2. We ask the LLM to create "real-world scenarios" or "vignettes" that exemplify these 2 or 3 general descriptions.
3. We ask the LLM to score the similarity between these "vignettes" and our games.
4. We could do something similar with the Aid and Bonus stories (that is, score their similarity with these vignettes).
5. Once we find something that "works" with LLMs, we can do this with human raters.

S

--

Salvatore Nunnari
Associate Professor
Department of Economics
Bocconi University
<https://snunnari.github.io>
<https://zoom.us/my/snunnari>

----- Forwarded message -----

From: **Salvatore Nunnari** <salvatore.nunnari@gmail.com>
Date: Wed, May 20, 2026 at 4:49 PM
Subject: Re: LLMs on Similarity between Stories and Games
To: Nicola Gennaioli <nicola.gennaioli@unibocconi.it>
Cc: Andrea Amelio <andrea.amelio@unibocconi.it>

[Quoted text hidden]